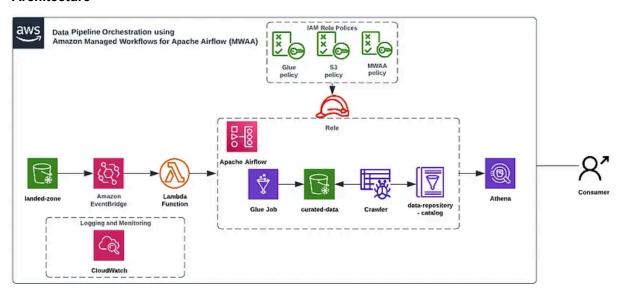
Fuente:

https://medium.com/contino-engineering/data-pipeline-orchestration-using-amazon-managed-workflows-for-apache-airflow-mwaa-60e5b213a0a7

Architecture

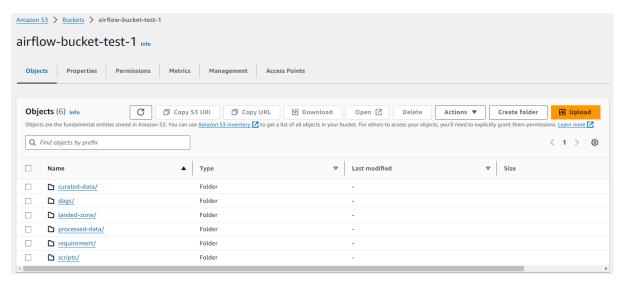


Process Overview

- 1. Create an S3 bucket using GUI.
- 2. Configure Amazon Managed Workflow for Apache Airflow (MWAA).
 - IAM Role: Create IAM roles and policies to use with MWAA.
 - S3 Bucket: S3 bucket to store your DAGs, plugins, and other Airflow files.
 - VPC and Subnet: To deploy an MWAA environment in a VPC and Subnet for secure and private network communication.
 - Security Groups: Create security groups to control MWAA environment access.
 - Monitoring and logging: Configure Amazon CloudWatch to monitor and log your MWAA environment.
- 3. Create the following AWS artifacts using the CloudFormation template:
 - IAM Role: Grant permission to AWS Glue and S3 services and attach this role with the AWS Glue job.
 - Glue Job: Converting CSV file to Parquet format and saving the curated file(s) into S3.
 - Crawler: Crawl and Catalog curated data using AWS Glue Crawler.
 - Catalog: Catalog the metadata of the process file.
- 4. Lambda function to trigger MWAA pipeline.
- 5. Upload the CSV data files to S3 (Landing Zone) bucket.
- 6. Query transformed data using AWS Athena.

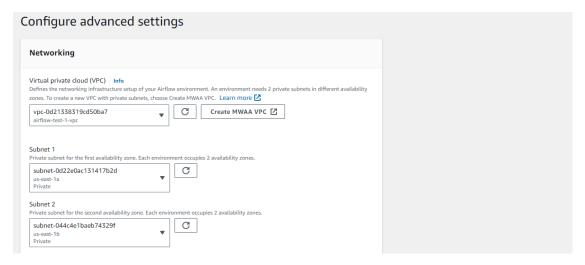
Creamos un bucket en S3 con la configuración básica. Luego agregamos los siguientes folders:

- curated-data: Store curated data in this folder.
- dags: Store DAGs code.
- landed-zone: Contains the raw data file to process.
- scripts: To save AWS Glue job script(s).
- processed-data: To move the processed raw data files.
- requirement: Contains DAG "requirement.txt" file.



Vamos al servicio MWAA y creamos un nuevo environment con la siguiente configuración:

- Asignamos un nombre y versión (última).
- Seleccionamos el bucket de s3 creado anteriormente y apuntamos a la carpeta dags.
- Creamos una VPC o elegimos una ya creada. Debe haber al menos 2 subnets privadas para seleccionarlas en la configuración.



- Elegimos un acceso público a través de internet.

Web server access Info
Private network (No internet access)
Additional setup required. Your Airflow UI can only be accessed by secure login behind your VPC. Choose this option if your Airflow UI is only accessed within a corporate network and you do not require a public repository for webserver requirements installation. IAM must be used to handle user authentication.

Public network (Internet accessible)

Your Airflow UI can be accessed by secure login over the Internet. Choose this option if your Airflow UI is accessed outside of a corporate network. IAM must be used to handle user authentication.

- Elegimos un security group o creamos uno desde cero. En este caso ya tenía uno creado.
- Elegimos un IAM role (para MWAA) o creamos uno desde cero. En este caso ya tenía uno creado.
- La configuración restante se deja por defecto.

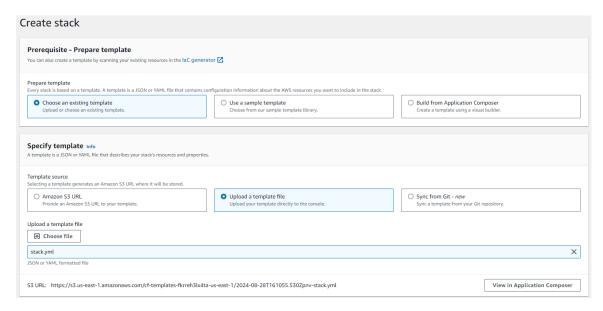
Esperamos de 20 a 30 minutos a que se cree el environment.

Creamos los demás servicios con apoyo del servicio CloudFormation, utilizando el template del tutorial.

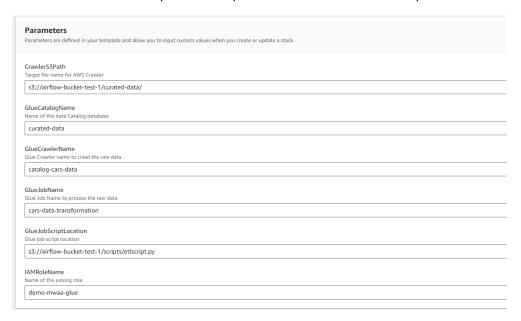
- IAM Glue role
- Glue crawler
- Glue data catalog
- Glue job

Dar el acceso completo a S3 (AmazonS3FullAccess) no es recomendable. Se deja así solo para el tutorial.

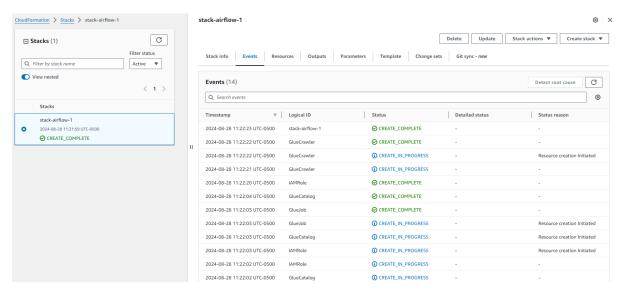
Elegimos el template que ya está en los archivos locales.



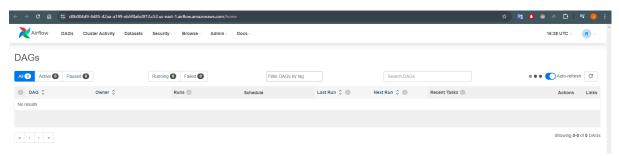
Al dar click en next nos aparecen los parámetros definidos en el template.



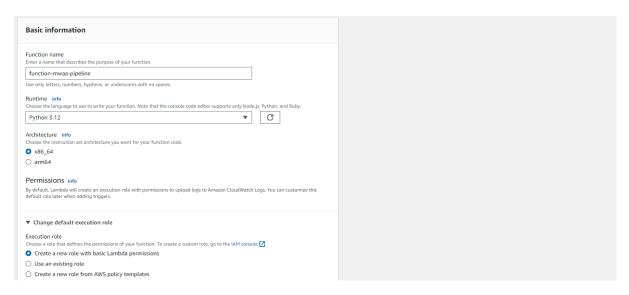
El stack de CloudFormation se ejecuta satisfactoriamente.



Verificamos el environment de Airflow al que ya se puede acceder.

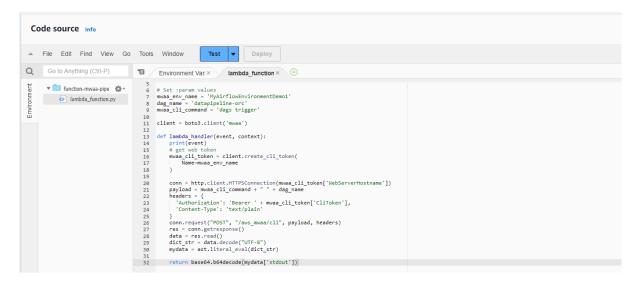


Ahora creamos la función Lambda.

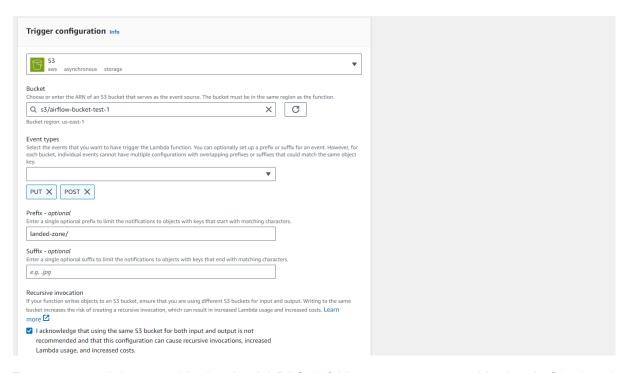


No apareció el rol que se creó para el environment de MWAA, por lo que creé uno nuevo con los permisos básicos de Lambda.

Agregamos el código proporcionado en el tutorial.



Agregamos un trigger a la función, apuntando al bucket de S3 al presentarse un evento post o put.

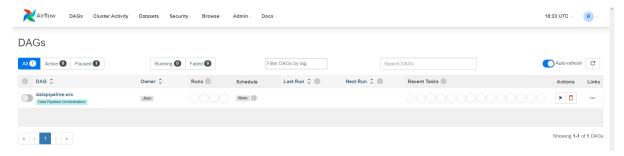


En este punto debemos subir el script del DAG al folder que tenemos en el bucket de S3, el cual contiene la siguientes tareas (tasks):

- begin: Starting the DAG point
- purge_data_catalog: Delete the data catalog
- purge_processed_data_s3_objects: Clean up the processed data folder in the S3 bucket
- run_glue_job: Trigger glue job to convert raw data file format from CSV to PARQUET
- run_glue_crawler: Crawler the curated-data folder and catalog the metadata of the processed file(s)
- sync_buckets: Copy landed-zone bucket objects to the processed-data folder
- purge raw data file: Clean up the landed-zone folder
- end: Show Data pipeline orchestration completion



Cargamos de nuevo la interface y nos aparece el DAG.

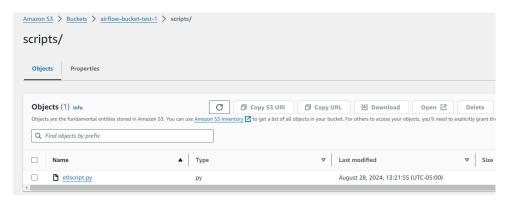


Damos click en el interruptor que se encuentra al lado del nombre de nuestro DAG, para dejarlo como *activo*.

DAGs



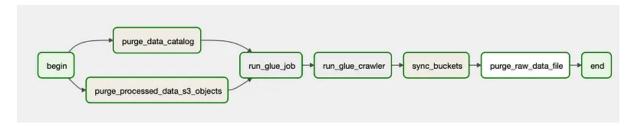
Algo que no se mencionó en el tutorial fue cargar el script del ETL de Glue en la carpeta de scripts del bucket de S3.



Cargamos la data (carsdata.csv) al folder landed-zone para activar la función Lambda y que esta a su vez inicie la ejecución del DAG en Airflow.

Se tuvo que añadir la action CreateCliToken al rol de MWAA y atar esta policy al rol de Lambda.

Luego termina de correr el DAG.



En este punto ya es posible ir hasta Athena y ver qué hay en la tabla curated_data.

